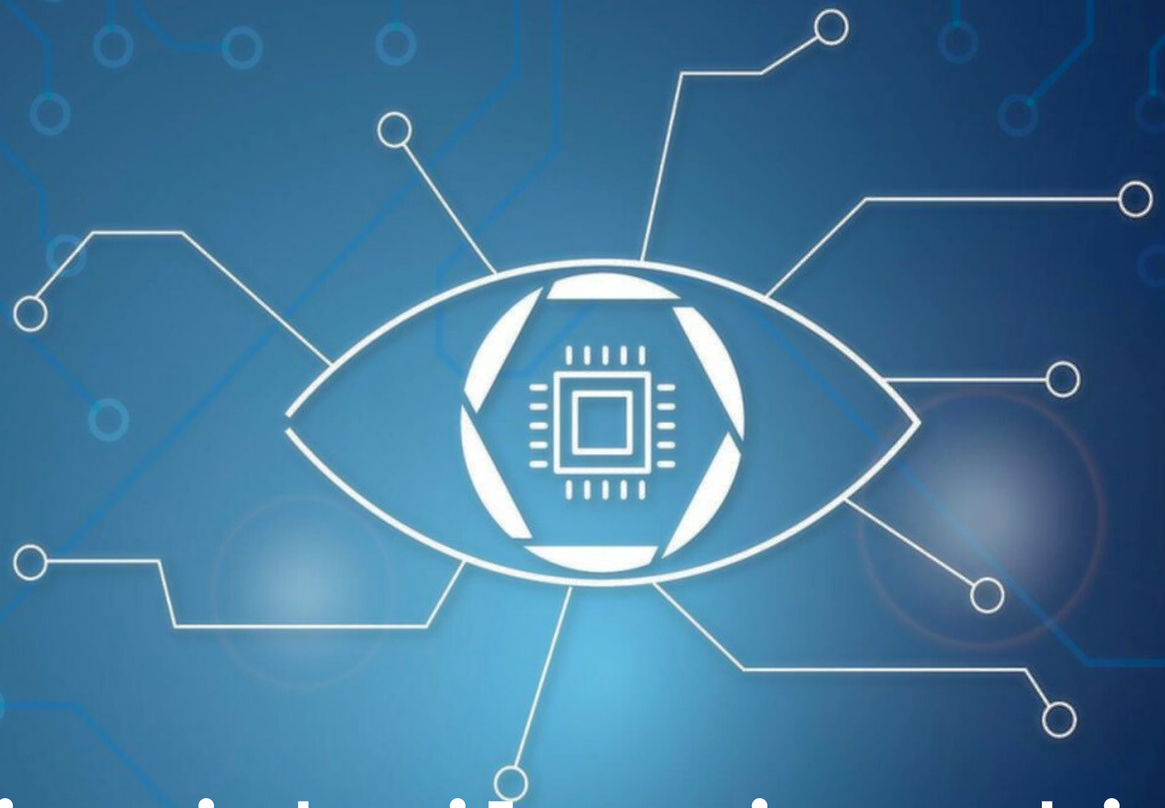
TUIASI innovate

Facultatea de AUTOMATICĂ ȘI CALCULATOARE din Iași



Detecția pietonilor și a vehiculelor în imagini din dronă

Manolescu Lavinia
Zaharia Andrei

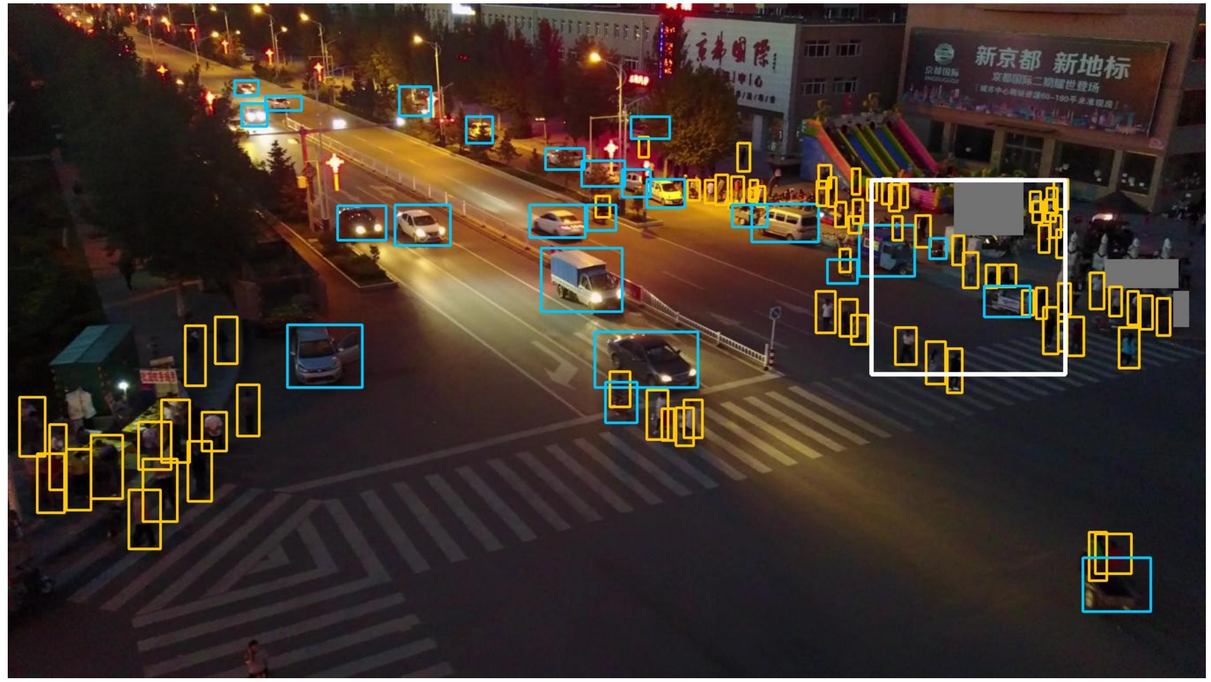
1. Context & Motivație

Context. Detecția pietonilor și a vehiculelor în imagini din dronă: obiecte foarte mici, dese, în lumină variabilă (zi, noapte, contrast slab).

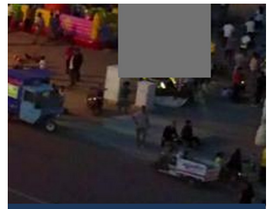
Date. VisDrone2019-DET, 10 clase; 6471 / 548 / 1610 imagini (train / val / test-dev), adnotate manual.

Problema. YOLO micșorează imaginea la 640 px pe latura mare. Pe imaginea din dreapta (1360×765, noapte), latura mediană a unui obiect scade de la 27 px la 13 px, iar 70% din obiecte ajung sub 16 px.

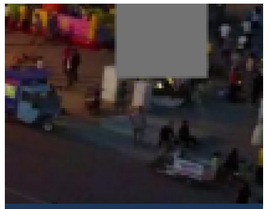
Obiectiv. Mai multă precizie pe obiectele mici, cu prelucrări în jurul detectorului YOLO26n: ferestre la rezoluție completă, CLAHE și ferestre adaptive, puse doar unde sunt obiecte.



etichete manuale, nu detecții · galben: pietoni · albastru: vehicule



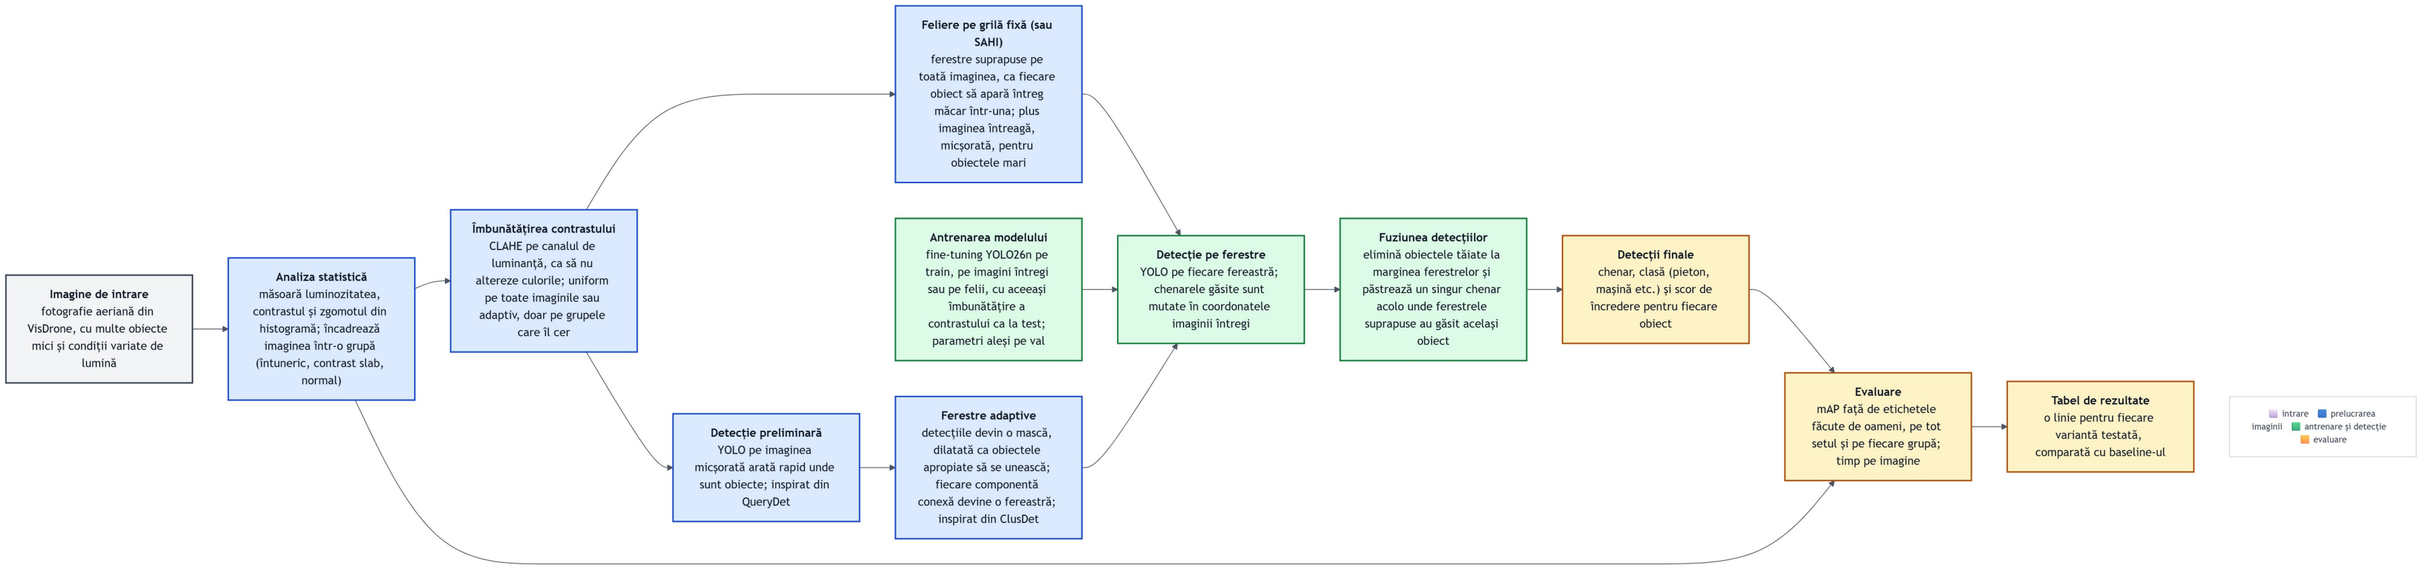
nativ



la 640 px

27 → 13 px latura
70% sub 16 px
100 obiecte etichetate

2. Arhitectura preliminară a soluției



Etapa 1 · grilă fixă

Imaginea se taie în ferestre de 640 px suprapuse 20%, analizate la rezoluție completă, plus imaginea întreagă micșorată. Alternativă: SAHI.

Etapa 2 · contrast

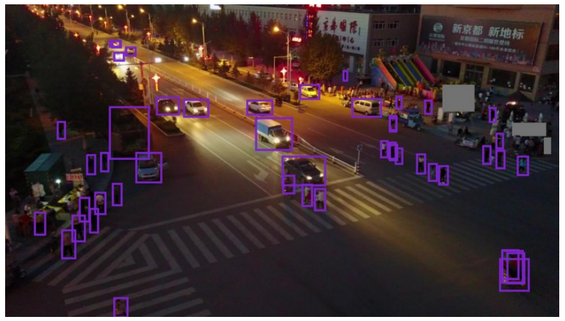
Analiza statistică încadrează imaginea pe grupe (întuneric, contrast slab, normal); CLAHE pe canalul L, pe toate imaginile sau doar pe grupele slabe.

Etapa 3 · ferestre adaptive

Detecția preliminară arată unde sunt obiecte; masca dilatată și componentele conexe dau ferestre doar acolo. Fără reantrenare.

2. Arhitectura preliminară a soluției

Etapa 3 · ferestre adaptive



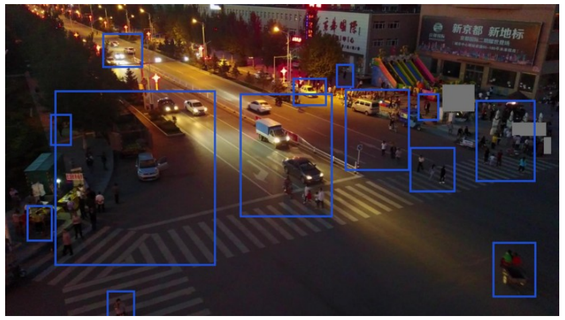
1 · Detecție preliminară: YOLO pe imaginea micșorată → 48 de casete



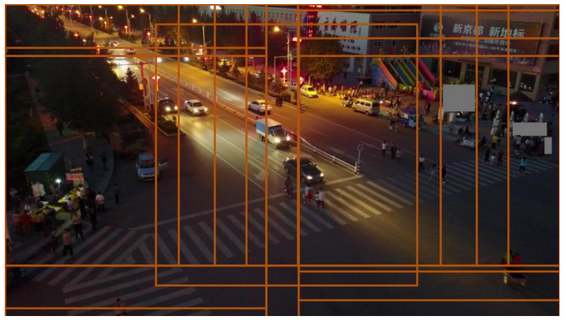
2 · Mască: casetele, albe, pe o mască de 640 px



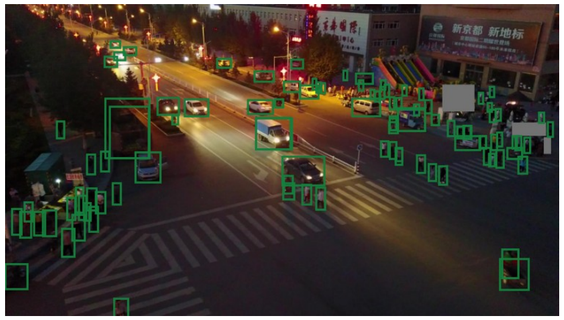
3 · Dilatare 15×15: grupurile apropiate se unesc → 13 pete



4 · Componente conexe: fiecare pată devine un dreptunghi



5 · Ferestre: margine 32 px, minim 640 px, în imagine → 13



6 · Detecții finale: ferestre + prima trecere, unite (IOS) → 101

Etapa 3, ferestre adaptive. Imagine din val (0000117_02708_d_0000090), model tiled, setări implicite: dilatare 15, margine 32, minim 640. Zonele gri sunt regiuni ignorate din adnotări.

De unde vine ideea

QueryDet: întâi o căutare grosieră, apoi detaliu doar unde e nevoie.

ClusDet: obiectele grupate în regiuni, analizate separat.

La noi: fără rețele în plus, doar operații clasice: binarizare, dilatare, componente conexe.

Pas nou: unirea ferestrelor

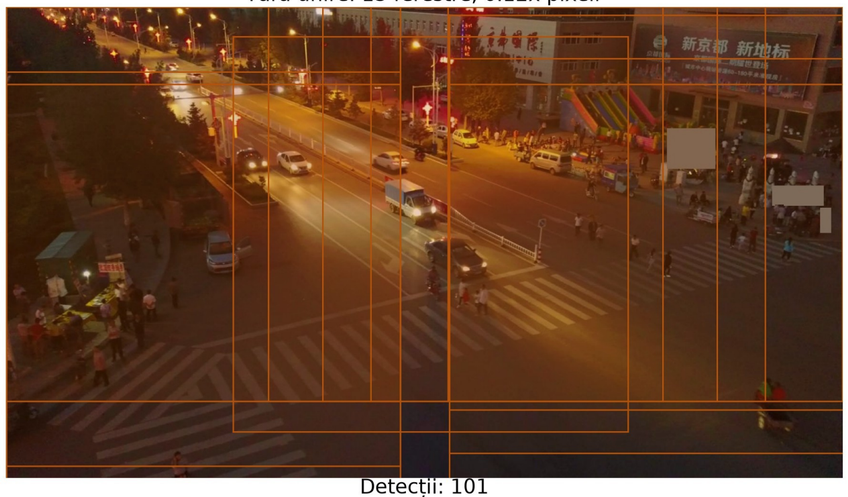
Cele 13 ferestre se suprapun mult. Ferestrele care se suprapun peste prag se unesc, cu plafon de mărime.

Aici: 13 → 3 ferestre, 6,12x → 2,51x pixeli.

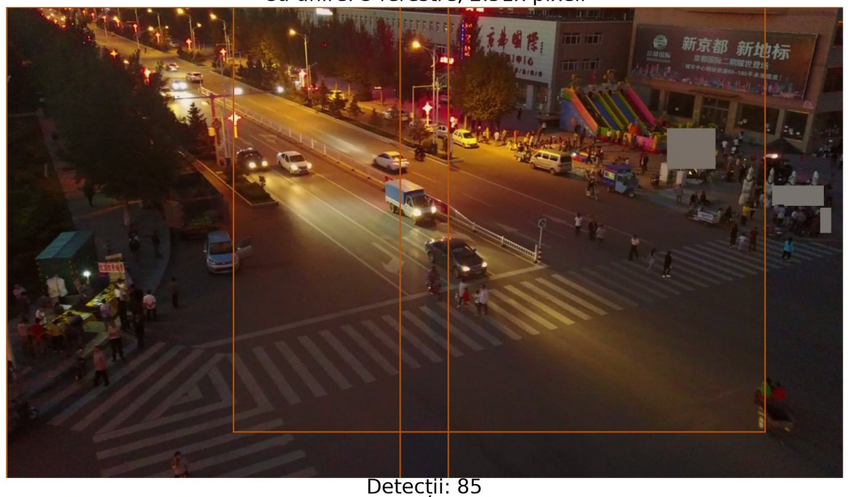
2. Arhitectura preliminară a soluției

Etapa 3 · unirea ferestrelor

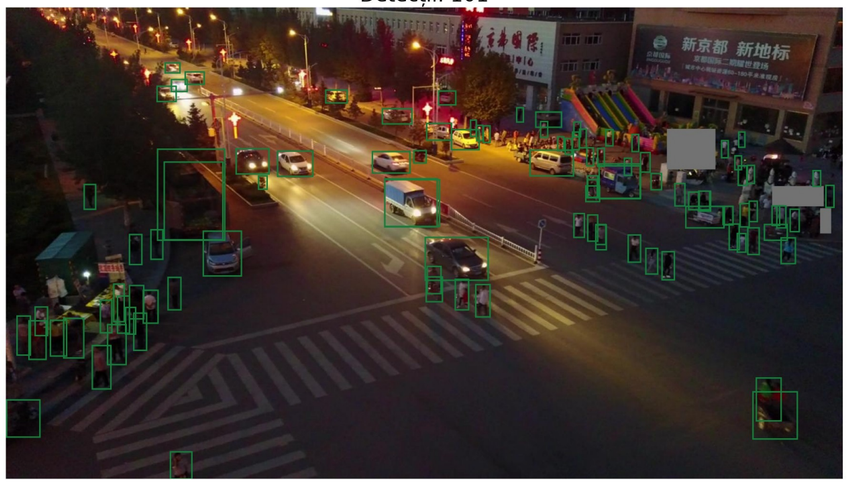
Fără unire: 13 ferestre, 6.12x pixeli



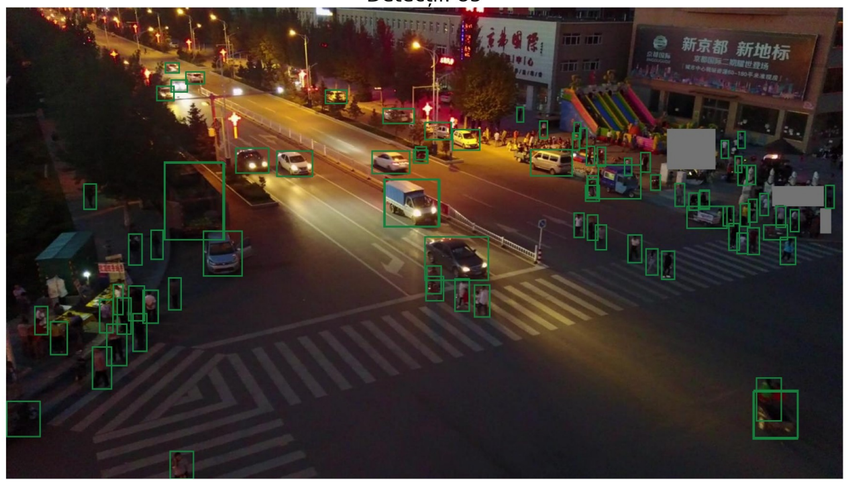
Cu unire: 3 ferestre, 2.51x pixeli



Detecții: 101



Detecții: 85



Etapa 3: cum se unesc

Două ferestre se unesc dacă suprapunerea / aria celei mici depășește 0,5 și fereastra unită are cel mult 960 px. Se repetă până nu mai e nimic de unit. Implicit e oprită.

Fără → cu unire

	noapte	zi
ferestre	13 → 3	6 → 1
pixeli	6,12x → 2,51x	5,01x → 1,95x
detecții	101 → 85	81 → 57

mAP50 pe val: fără unire 0,502 → prag 0,3: 0,436, prag 0,7: 0,443.

Unirea scade mAP-ul. Ipoteză (netestată): fereastra unită se micșorează la 640 px și obiectele mici se pierd.

3. Evaluarea Preliminară a Soluției

Metrici. mAP50 și mAP50-95 (media pe pragurile IoU 0,50…0,95), timp pe imagine, ferestre pe imagine, pixeli procesați față de imaginea întreagă.

Aceleași condiții. Un singur evaluator pentru toate variantele, pe imaginea întreagă, cu etichetele originale: același prag (conf 0,001), același plafon de detecții (300; 317 pe val).

Date. Deciziile se iau pe val (548 de imagini). Test-dev (1610) rulează o singură dată, la final. La fiecare etapă se adaugă o componentă, păstrată doar dacă crește mAP-ul pe val.

Imagini pe grupe de iluminare

Split	normal	întuneric	contrast slab
train	4736	1139	596
val	431	13	104
test-dev	1032	501	77

Pe val sunt doar 13 imagini întunecate: concluziile pentru noapte se verifică pe test-dev (501).

Cum citim mAP. mAP50 = un scor între 0 și 1 care combină câte obiecte sunt găsite și câte alarme false apar. O casetă e corectă dacă se suprapune cel puțin 50% cu cea etichetată. mAP50-95 e mai strict: o medie pe praguri de la 50% la 95%.

Etapa 1
baseline · SAHI · grilă: câștigă grila

Etapa 2
CLAHE: nu ajută pe val

Etapa 3
adaptive: mAP mai mare, dar mai lent

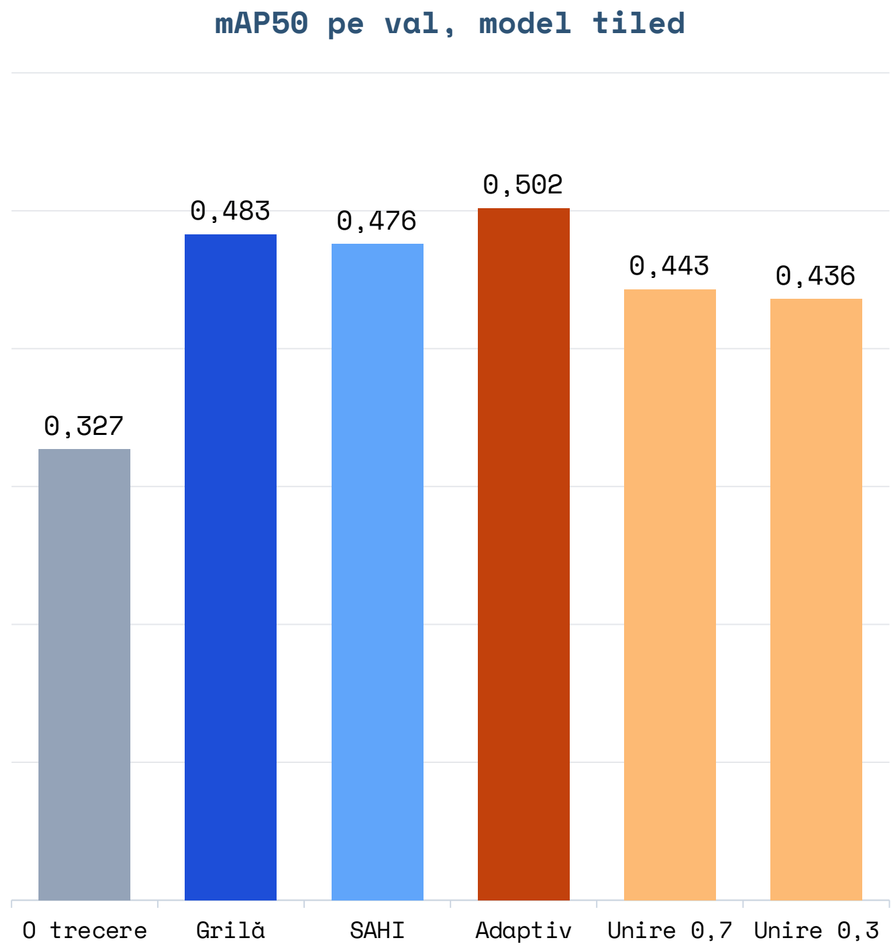
Test-dev
o singură rulare, la final

4. Rezultate Preliminare

val · 548 imagini

Variantă	mAP50	mAP50-95	pixeli
Baseline, o trecere	0,307	0,173	1,00×
Baseline + grilă	0,392	0,223	≈3,4×
Baseline + SAHI	0,384	0,217	≈3,4×
Tiled, o trecere	0,327	0,189	1,00×
Tiled + grilă	**0,483**	**0,292**	**≈3,4×**
Tiled + SAHI	0,476	0,284	≈3,4×
Tiled + adaptiv	**0,502**	**0,304**	**5,5×**
Adaptiv + unire 0,7	0,443	0,266	2,36×
Adaptiv + unire 0,3	0,436	0,261	2,29×

Val, 548 imagini, prag 0,001. Pixeli = 1 + suma ariilor ferestrelor / aria imaginii; grila: ≈3,4× la 1360×765, mai puțin la imaginile mici. Evidențiat: varianta aleasă; bold: cel mai mare mAP.



Felii: cu grilă, 0,392 → 0,483. SAHI dă 0,476, sub grilă, și e mult mai lent (≈200 ms față de ≈40; orientativ).

Adaptiv: 0,502, cu 0,019 peste grilă, dar 5,5× pixeli și cam de 3 ori mai lent: de aceea alegem grila.

Unirea ferestrelor: mAP50 0,44, sub grilă și sub adaptiv. Cu cât unești mai puțin, cu atât mai bine (0,7 > 0,3).

4. Rezultate Preliminare

val · 548 imagini

CLAHE, grilă pe tiled (mAP50)

Model	total	dark	contr. slab	normal
fără CLAHE	0,483	0,573	0,503	0,479
CLAHE uniform	0,482	0,571	0,494	0,480
CLAHE adaptiv	0,484	0,562	0,468	0,483

Cu imaginea întreagă: 0,327 / 0,325 / 0,326. Pe val, CLAHE nu schimbă rezultatul (≤ 0,002 pe total).

Concluzie: rămâne tiled + grilă, fără CLAHE. Grupa dark are 13 imagini, deci noaptea se judecă pe test (501): acolo verificăm CLAHE adaptiv.

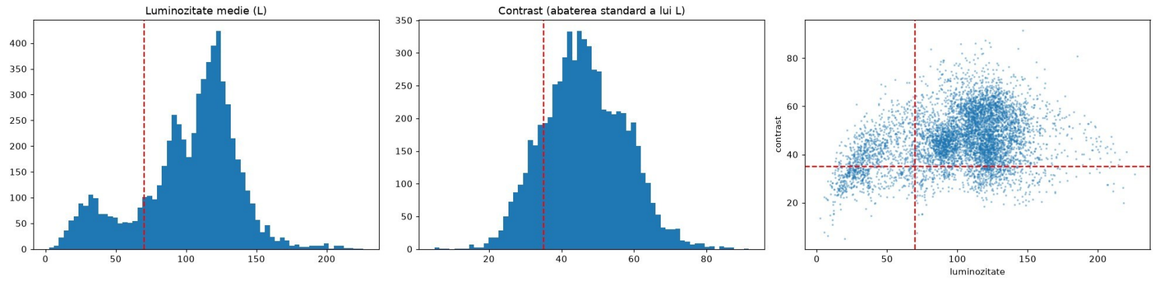
Tiled bate baseline pe toate grupele. Adaptivul e cel mai bun pe contrast slab și normal; unirea e sub grilă peste tot.

Luminozitatea are două vârfuri: noaptea (~30–40) și ziua (~120). Linia de la 70 trece deasupra vârfului de noapte, cea de la 35 e în coada de jos a contrastului.

Pe grupe de iluminare (mAP50)

Variantă	dark 13	contr. 104	normal 431
Baseline	0,401	0,307	0,303
Baseline + grilă	0,448	0,370	0,391
Tiled + grilă	**0,573**	**0,503**	**0,479**
Tiled + SAHI	0,580	0,497	0,472
Tiled + adaptiv	0,565	0,524	0,498
Adaptiv + unire 0,7	0,528	0,483	0,437
Adaptiv + unire 0,3	0,516	0,476	0,429

Pragurile 70 și 35 pe histograme



4. Rezultate Preliminare

val · 548 imagini

Pe clase (mAP50-95): grilă, apoi ferestre adaptive

Clasă	baseline + grilă	tiled + grilă	tiled + adaptiv	câștig
pedestrian	0,226	0,289	0,298	+28%
people	0,127	0,182	0,191	+42%
bicycle	0,054	0,138	0,144	+157%
motor	0,203	0,293	0,300	+44%
car	0,561	0,602	0,608	+7%
van	0,272	0,329	0,344	+21%
truck	0,196	0,298	0,314	+52%
bus	0,387	0,477	0,505	+23%
tricycle	0,137	0,211	0,220	+55%
awning-tricycle	0,070	0,103	0,119	+48%

Val, 548 imagini, prag 0,001. pedestrian = om care merge sau stă; people = om în alte poziții. baseline: antrenat pe imagini întregi; tiled: antrenat pe felii de 640 px; primele două testate cu aceeași grilă. Câștig = tiled + grilă față de baseline + grilă.

Cum se alege clasa

YOLO26n prezice odată caseta și clasa, una din cele 10 din VisDrone, deci pieton sau mașină se decide în rețea. Ferestrele nu schimbă asta. Când detecțiile din ferestre se combină, dublurile se elimină doar între casete din aceeași clasă.

Ce arată

Câștigul relativ e mare la clasele cu scor mic de la început (bicycle 0,054 → 0,138, truck +52%) și mic la car, care pornește de la 0,561.

Adaptivul adaugă încă 0,006–0,028 peste grilă, la toate clasele.

5. Concluzii Preliminare

+57%
mAP50: tiled + grilă față de baseline cu o singură trecere (0,307 → 0,483)

±0,002
cât schimbă CLAHE mAP50 pe val: nu ajută (0,482 și 0,484 față de 0,483)

-0,06
mAP50 pierdut prin unirea ferestrelor (0,502 → 0,44): rezultat negativ

Progres

Pipeline complet, cu teste: date, analiză statistică, CLAHE, grilă, SAHI, ferestre adaptive, un singur evaluator. Patru modele antrenate complet pe RTX și evaluate pe val, pe grupe. Aplicație demo cu urmărire în video.

Limitări

Unirea ferestrelor ieftinește (2,3× pixeli), dar scade mAP-ul la 0,44. Noaptea: 13 imagini în val, 501 în test.

Îmbunătățiri

De testat: ferestrele unite rulate la rezoluție mai mare, nu micșorate la 640 px. Reglarea dilatării și a mărimii minime pe modelul tiled. CLAHE adaptiv verificat pe test, pentru noapte.

Varianta aleasă: tiled + grilă (0,483 mAP50). Tiled + ferestre adaptive are cel mai bun mAP (0,502), dar cu 5,5× pixeli și de ~3 ori mai lent, deci la final alegem grila. Toate cifrele sunt pe val și preliminare; test-dev nu a fost încă rulat.

6. Direcții Viitoare

1. **Aceeași precizie, mai puțin calcul**
   căutăm ferestre mai puține, ca drona să proceseze mai repede fără să rateze obiectele mici

2. **Noaptea**
   verificăm pe cele 501 imagini de noapte din setul de test dacă îmbunătățirea contrastului ajută

3. **De la imagini la video**
   ferestrele urmăresc pietonii și mașinile de la un cadru la altul; aplicația are deja urmărire

4. **Aplicații în trafic**
   numărăm pietonii și vehiculele pe zone; mai departe, situații riscante, de exemplu traversări în afara trecerii

La ce ar putea ajuta

O dronă care numără și urmărește pietonii și vehiculele ar putea semnala aglomerări și situații periculoase, fără camere fixe.

Obiectiv final

Un tabel cu toate variantele: cât de precise sunt, cât de repede merg și cum se descurcă noaptea. Verdictul vine din setul de test, rulat o singură dată.

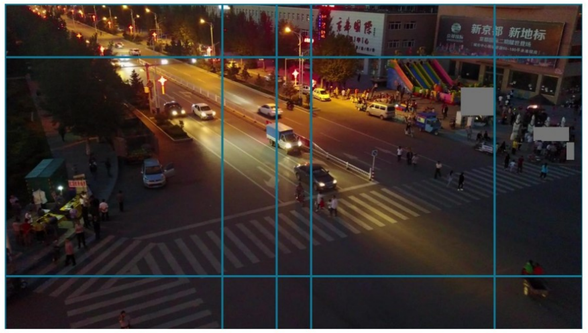
Anexă: etapele metodei

Noapte · imagine din val (0000117_02708_d_0000090); detecțiile: model tiled + ferestre adaptive

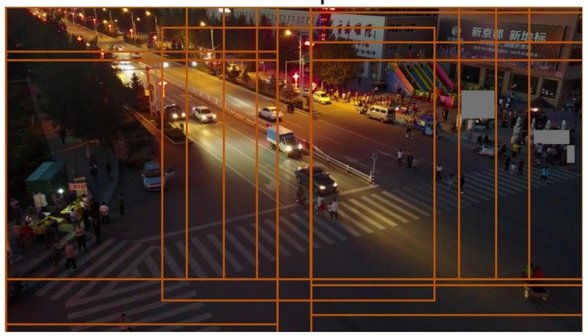
Imaginea originală



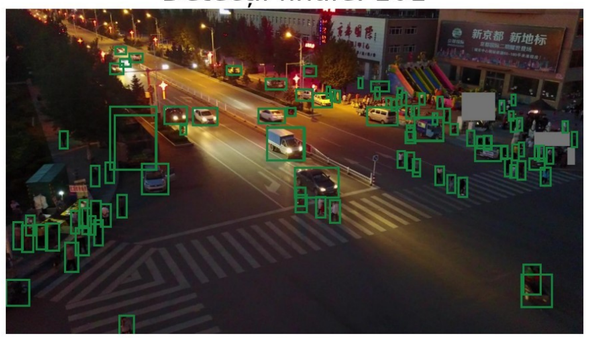
Grila de ferestre: 6



Ferestre adaptive: 13



Detecții finale: 101



turcoaz: grila · portocaliu: ferestre adaptive · verde: detecții

Fuziunea, comună: casetele tăiate de marginea unei ferestre se aruncă; dublurile de aceeași clasă se elimină după IOS = intersecția / aria casetei mai mici.

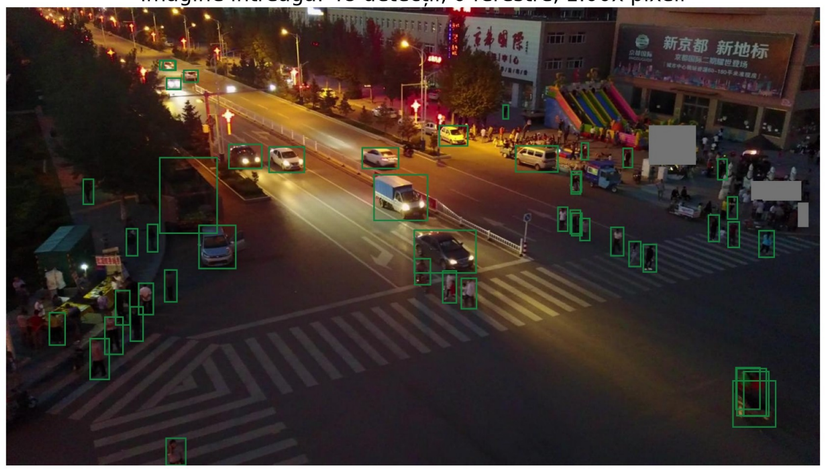
CLAHE: pe val nu schimbă mAP-ul (0,482–0,484 față de 0,483), deci imaginile de mai sus sunt fără CLAHE.

Pe această imagine (1360×765): grila are 6 ferestre, cele adaptive 13 (6,12× pixeli), iar detecțiile finale sunt 101. mAP-ul din slide-urile de rezultate e calculat pe tot setul val (548 imagini), nu pe o singură imagine.

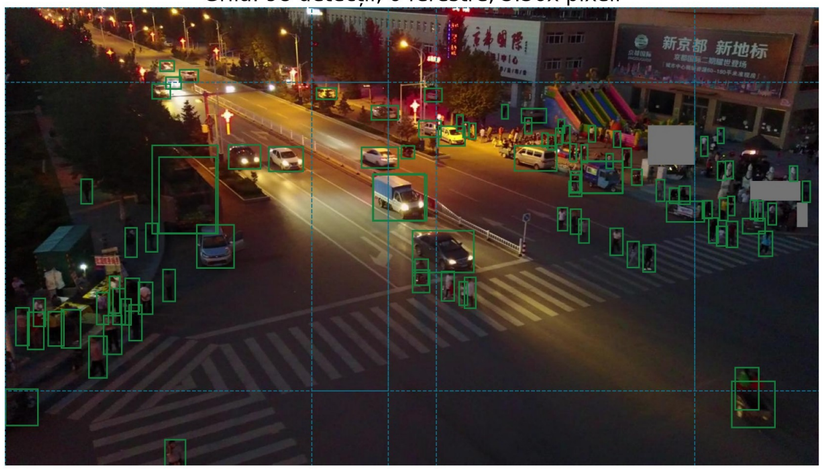
Anexă: rezultate pe o imagine

model tiled

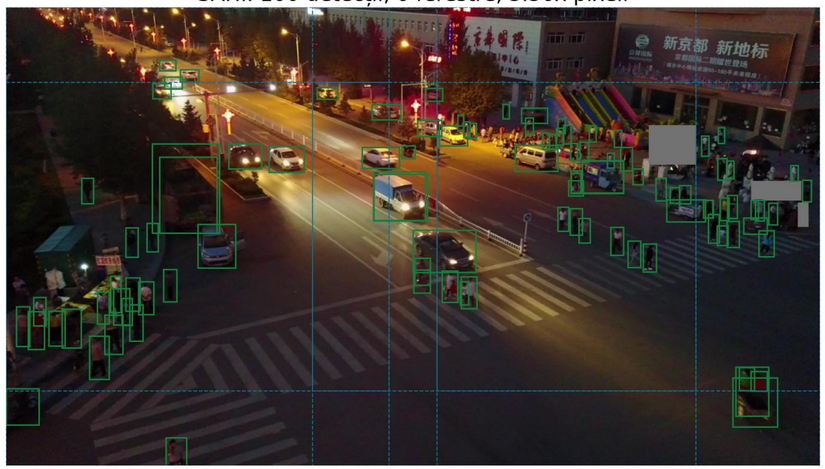
Imagine întreagă: 48 detecții, 0 ferestre, 1.00x pixeli



Grilă: 98 detecții, 6 ferestre, 3.36x pixeli



SAHI: 100 detecții, 6 ferestre, 3.36x pixeli



Ferestre adaptive: 101 detecții, 13 ferestre, 6.12x pixeli



Imaginea de noapte (1360×765)

metodă	det. · pixeli	mAP50
întreagă	48 · 1,00x	0,327
grilă	98 · 3,36x	0,483
SAHI	100 · 3,36x	0,476
adaptiv	101 · 6,12x	0,502
adaptiv+unire	85 · 2,51x	0,44

Prag de afișare 0,25. Pixeli = 1 + suma ariilor ferestrelor / aria imaginii. mAP50: pe tot val, nu doar pe această imagine; unirea, la pragurile 0,3 și 0,7.

Mai multe casete nu înseamnă mai bine: grila (98), SAHI (100) și adaptivul (101) au aproape aceleași casete, dar mAP50 diferă (0,483, 0,476, 0,502). O singură trecere are jumătate din casete și 0,327.

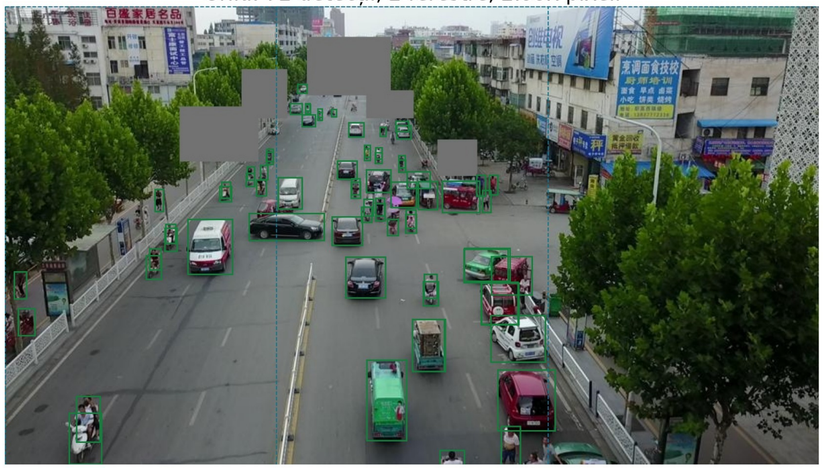
Anexă: imaginea de zi

model tiled

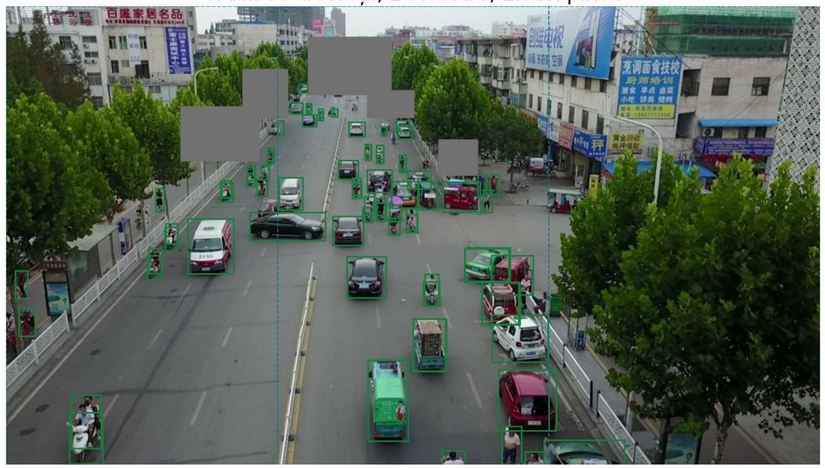
Imagine întreagă: 53 detecții, 0 ferestre, 1.00x pixeli



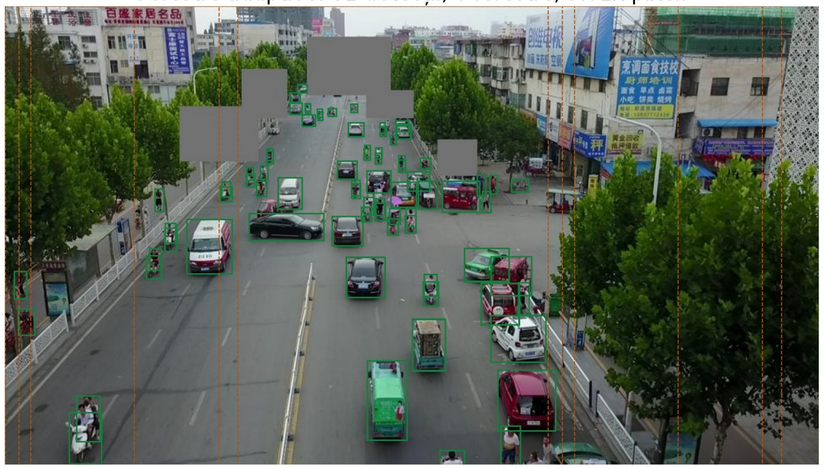
Grilă: 72 detecții, 2 ferestre, 2.33x pixeli



SAHI: 77 detecții, 2 ferestre, 2.33x pixeli



Ferestre adaptive: 81 detecții, 6 ferestre, 5.01x pixeli



Imaginea de zi (960×540)

metodă	det. · pixeli	mAP50
întreagă	53 · 1,00x	0,327
grilă	72 · 2,33x	0,483
SAHI	77 · 2,33x	0,476
adaptiv	81 · 5,01x	0,502
adaptiv+unire	57 · 1,95x	0,44

Imagine mică: grila are doar 2 ferestre, iar adaptivul implicit 6, cu minimul de 640 px. Unirea le face una singură: pixeli mai puțini, dar și detecții mai puține (81 → 57). mAP50: pe tot val; unirea, la pragurile 0,3 și 0,7.